

TP Express : Architecture et Administration Hadoop HDFS

Dr. EL BENANY Mohamed Mahmoud

Mai 2026

1 Infrastructure et Déploiement

Le cluster simule un environnement distribué via Docker (1 NameNode, 2 DataNodes, YARN).

Exercice 1 : Analyse et Lancement

1. Examinez le `docker-compose.yml`. Pourquoi le `datanode2` est-il mappé sur le port `9865:9864` au lieu de `9864:9864` ?
2. **Diagnostic** : Une fois démarré, vérifiez l'état : `docker-compose ps`. Que signifie le statut `healthy` pour le NameNode ?
3. **Validation Web** : Accédez à `http://localhost:9870`. Combien de DataNodes sont "Live" ?

2 Manipulation de Données (HDFS Shell)

L'objectif est de gérer un dataset réel (*NYC Taxi Trip*, 500 Mo).

Exercice 2 : Ingestion et Consultation

1. Créez le répertoire cible : `hdfs dfs -mkdir -p /tphdfs/data`.
2. Chargez le dataset : `hdfs dfs -put /tp/data/nyctrip.csv /tphdfs/data/`.
3. **Question** : Utilisez `hdfs dfs -stat "%r"` sur ce fichier. Quel est le facteur de réplication par défaut ?
4. Changez la réplication à 2 : `hdfs dfs -setrep -w 2 /tphdfs/data/nyctrip.csv`. Pourquoi l'option `-w` est-elle utile ?

Exercice 3 : Analyse des Blocs (Le cœur du Big Data)

1. Lancez le diagnostic : `hdfs fsck /tphdfs/data/nyctrip.csv -files -blocks -locations`.
2. **Analyse** : En combien de blocs le fichier est-il découpé ? Pourquoi n'est-il pas stocké en un seul bloc ?
3. **Tolérance aux pannes** : Arrêtez le `datanode1` (`docker stop`). Le fichier est-il toujours lisible via `hdfs dfs -cat | head` ? Pourquoi ?

3 Administration et Exercices d'Autonomie

Apprenez à gérer les flux complexes et la sécurité POSIX de HDFS.

Exercice 4 : Gestion Avancée

1. **Fusion** : Fusionnez plusieurs rapports locaux vers HDFS en un seul export : `hdfs dfs -getmerge /exercices/rapports /tmp/fusion.txt`.
2. **Droits** : Changez le propriétaire de `personnes.txt` en `root:supergroup` et passez les permissions en 600. Qui peut encore lire le fichier ?
3. **Flux** : Ajoutez une ligne de log à un fichier HDFS sans le ré-uploader via `-appendToFile`.

4 Clôture et Maintenance

Exercice 5 : Nettoyage du Cluster

1. Arrêtez le cluster
2. **Réflexion** : Si vous relancez le cluster sans l'option `-v`, vos fichiers sont-ils perdus ?
3. **Commande Critique** : Quelle commande supprime TOUT (conteneurs + données) ? Quel est son danger en production ?

Tableau Récapitulatif (À compléter par l'étudiant)

Concept	Définition / Utilité constatée pendant le TP
NameNode	
DataNode	
Block Size	
Replication Factor	
FSCK	

Validation Enseignant : / 20
